Topic modeling

Hyunjoong Kim

soy.lovit@gmail.com

github.com/lovit

Latent Semantic Indexing (LSI)

probabilistic Latent Semantic Indexing (pLSA)

Latent Dirichlet Allocation (LDA)

Latent Semantic Indexing (LSI)

- Latent Semantic Analysis (LSA)라고도 불립니다.
- 단어 – 문서 행렬에 SVD 를 적용하여 단어와 문서를 토픽 공간의 벡터로 표현합니다.
  - $m \times n$ (단어, 문서) 행렬이
  - $m \times t$, $t \times n$ 의 (단어, 토픽), (토픽, 문서) 행렬로 분해됩니다.

https://cs.stanford.edu/~ppasupat/a9online/1140.html

Singular Value Decomposition

- SVD 는 행렬 A 를 다음처럼 세 개의 행렬로 분해합니다.

$$A = U\sum V^T$$

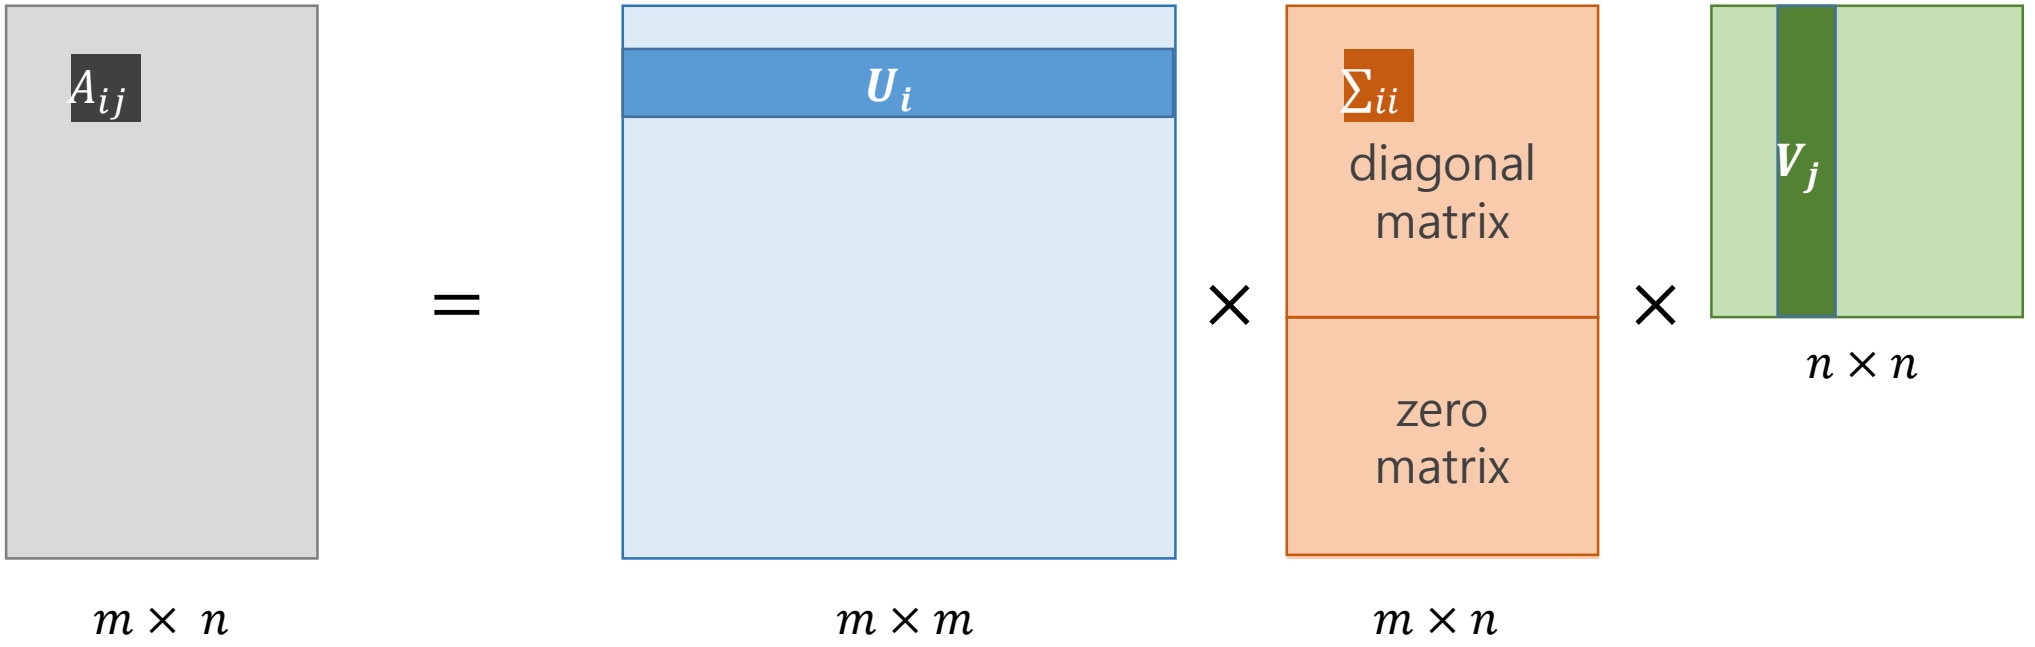

Singular Value Decomposition

- U, V 는 각각 orthonormal matrix 입니다.
  - 각 행과 열의 벡터의 크기는 1 이며 (normal)
  - $U_i \times U_j^T = 0, U_i \cdot U_i^T = 1$ 입니다.
  - V 도 동일합니다.

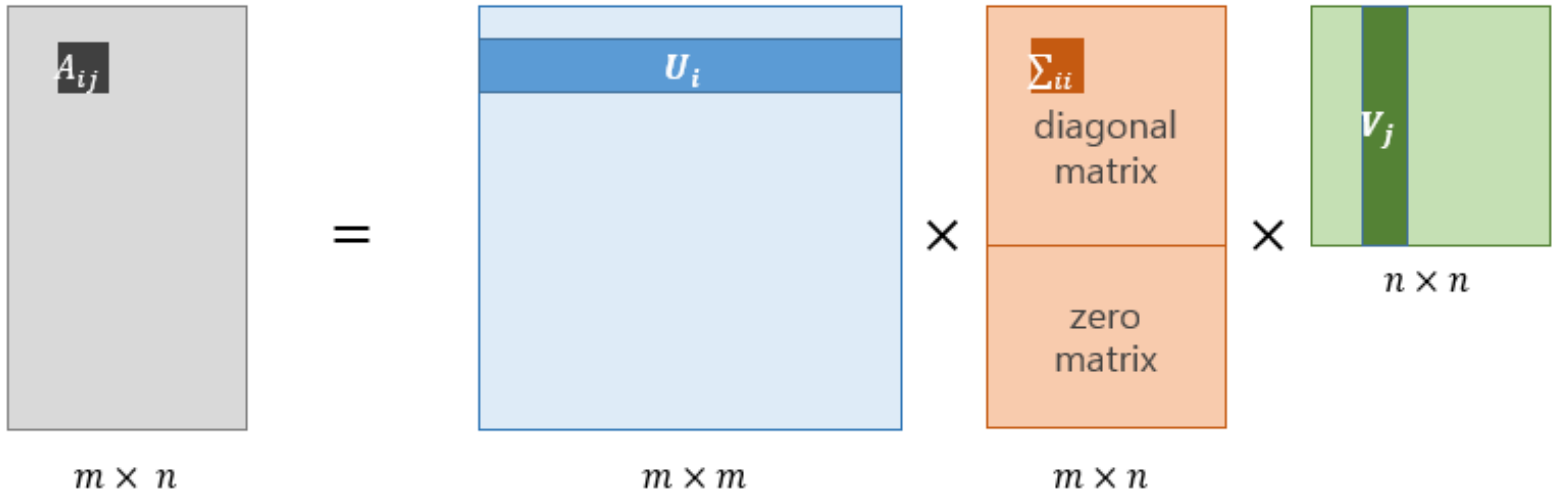

Singular Value Decomposition

- $\sum$ 는 PCA 에서의 각 component 별 중요도 (variance proportion) 입니다.
  - $\min(m, n)$ 개의 components 에 대한 중요도로 해석할 수 있습니다.

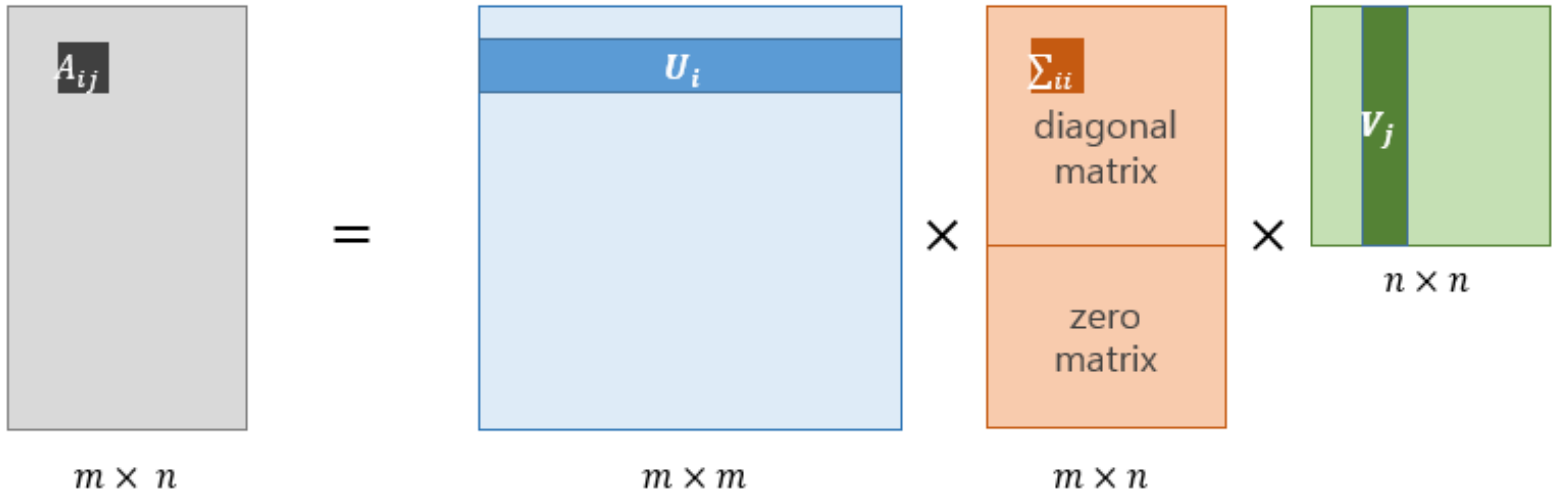

Singular Value Decomposition

- truncated SVD 는 $\sum$ 에서 중요한 k 개의 components 만 이용합니다.
  - U, V 를 k 차원으로 축소한 것으로 해석할 수 있습니다.

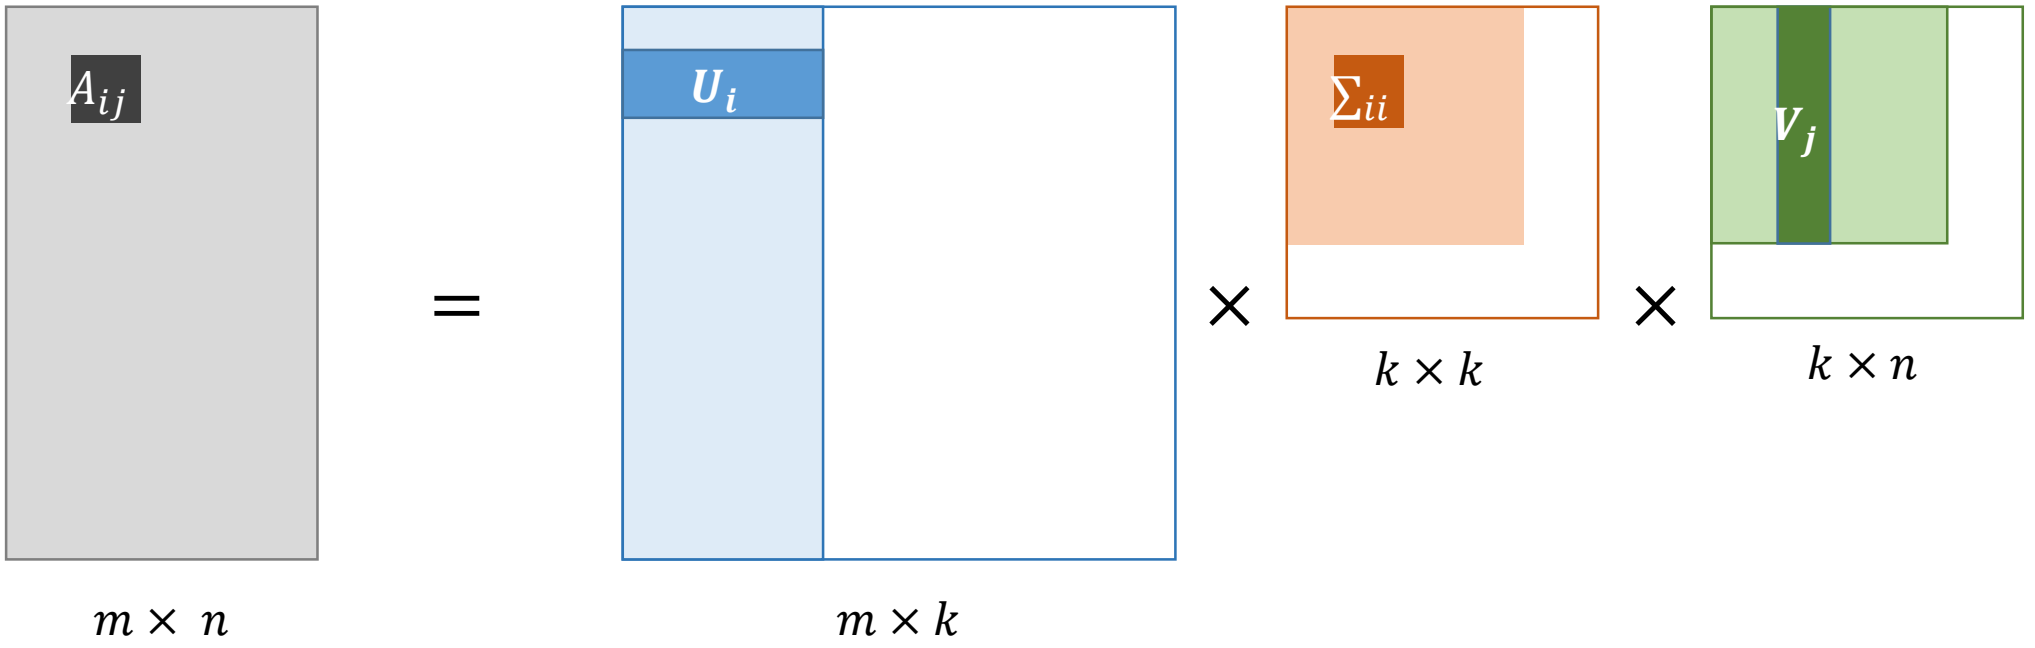

Singular Value Decomposition

- Top principal components 에서 중요한 정보들은 추출이 되었기 때문에 정보의 손실이 적습니다.
- 비슷한 문서들에서 함께 등장한 단어들의 정보가 각 components 에 저장됩니다.

Latent Semantic Indexing (LSI)

- LSI 는 함께 등장하는 단어 집합을 하나의 개념 (토픽)으로 묶는 효과가 있습니다. (co-occurrence)

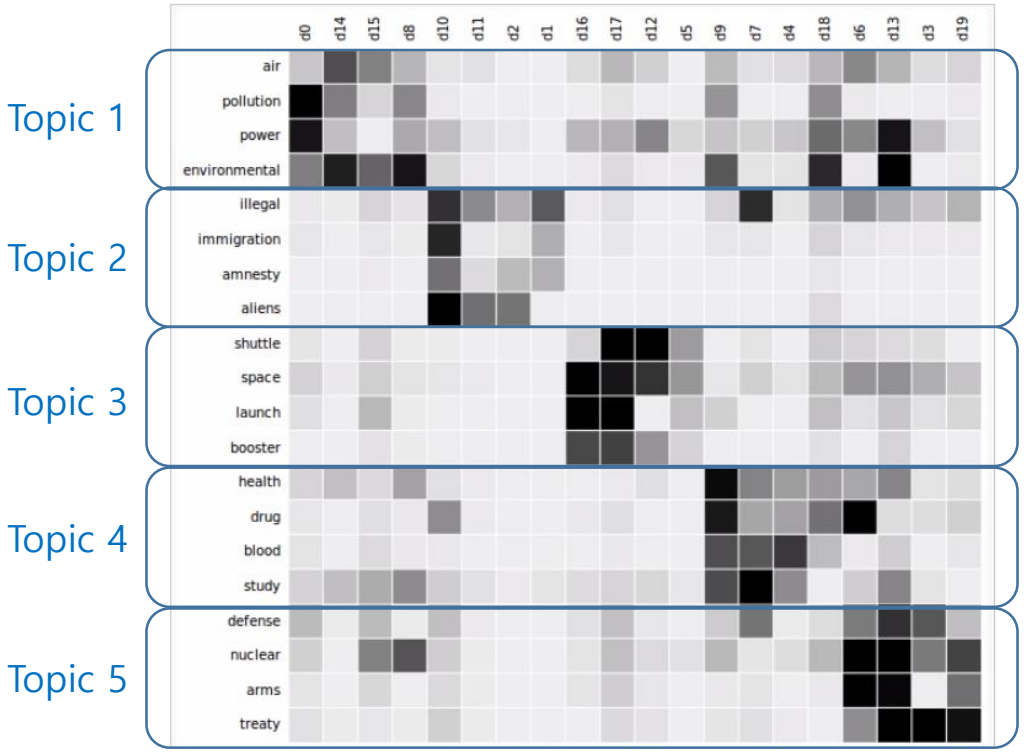

https://en.wikipedia.org/wiki/Latent_semantic_analysis

Latent Semantic Indexing (LSI)

- LSI 는 k 차원의 벡터로 단어와 문서를 표현합니다.
  - Topic 에 관련된 정보를 보존하는 차원압축 방법입니다.

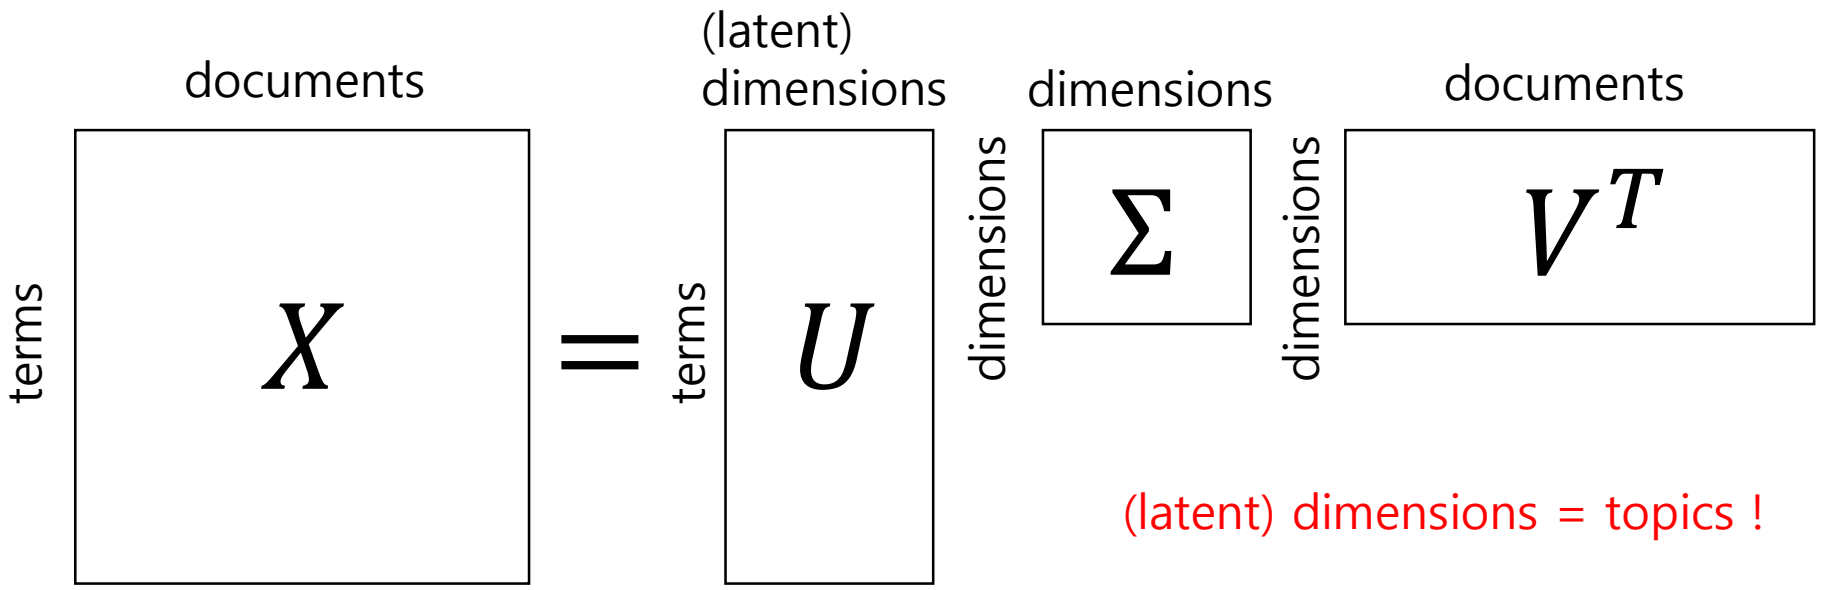

Latent Semantic Indexing (LSI)

First two topics much more important than other topics.

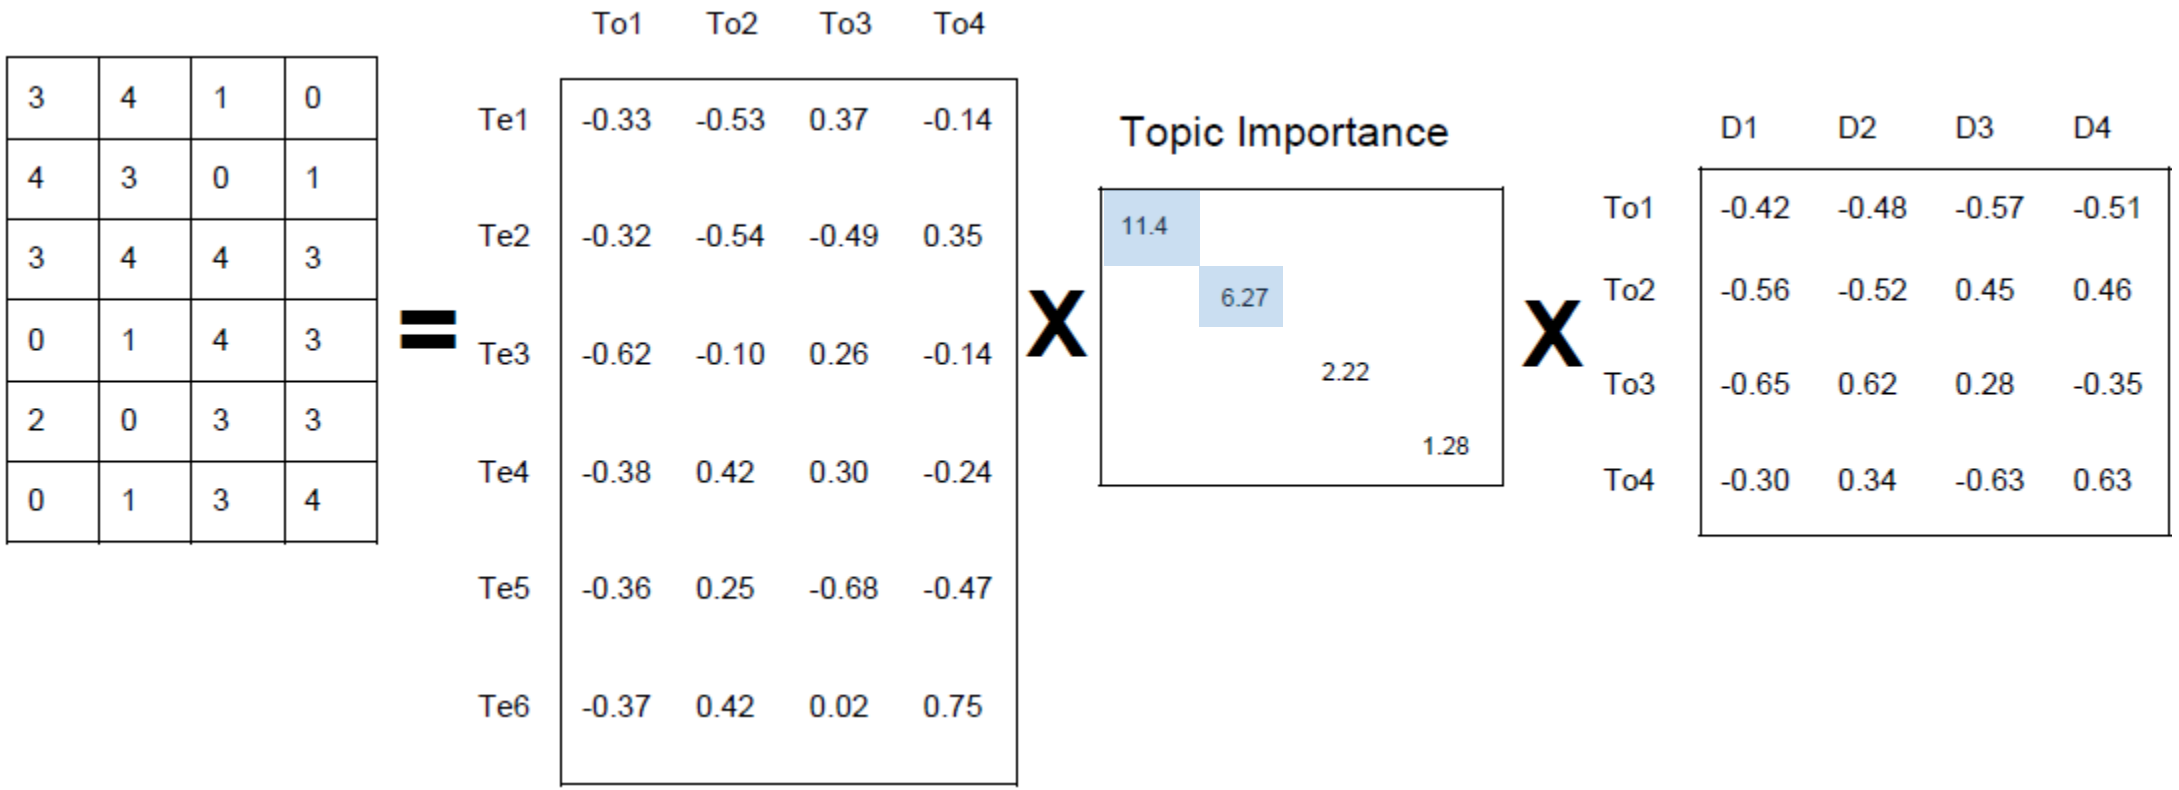

Example from LAK15 tutorial "Topic modeling for learning analytics researchers" by V. Kovanovic et al.

Latent Semantic Indexing (LSI)

두 components 에 Term 1, 2 의 유사성이 보존됩니다.

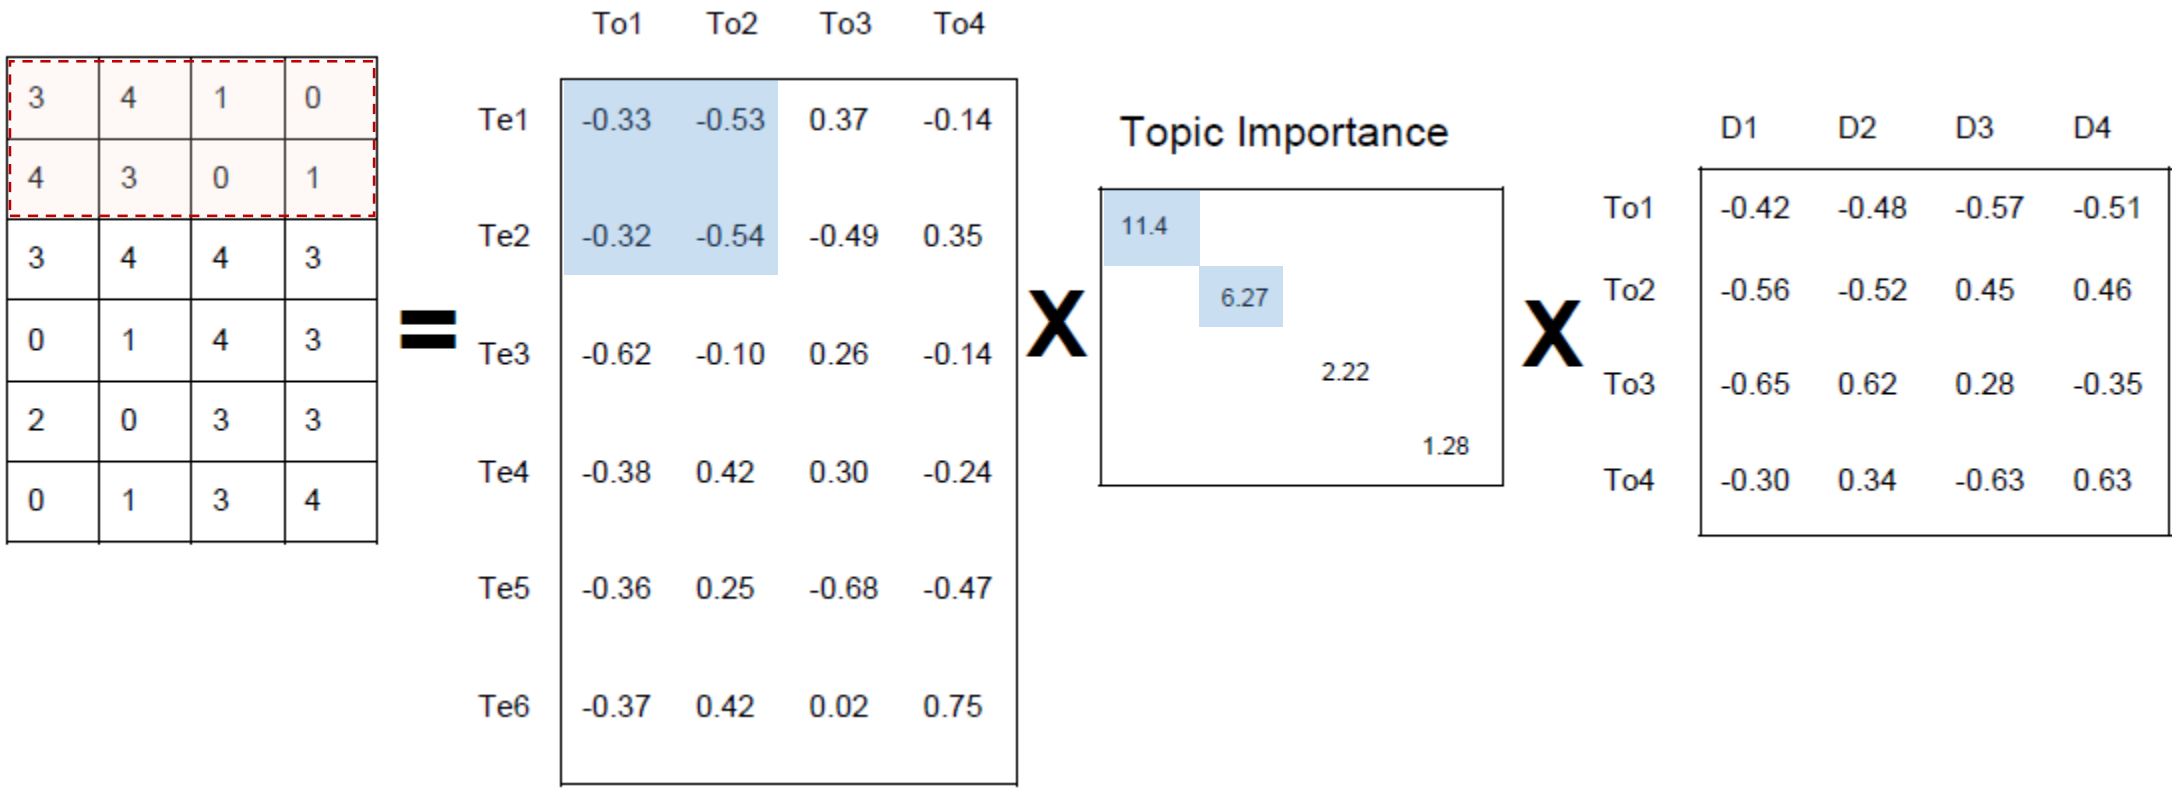

Example from LAK15 tutorial "Topic modeling for learning analytics researchers" by V. Kovanovic et al.

Latent Semantic Indexing (LSI)

두 components 에 Term 4, 5, 6 의 유사성이 보존됩니다.

3	4	1	0
4	3	0	1
3	4	4	3
0	1	4	3
2	0	3	3
0	1	3	4

=

	To1	To2	To3	To4
Te1	-0.33	-0.53	0.37	-0.14
Te2	-0.32	-0.54	-0.49	0.35
Te3	-0.62	-0.10	0.26	-0.14
Te4	-0.38	0.42	0.30	-0.24
Te5	-0.36	0.25	-0.68	-0.47
Te6	-0.37	0.42	0.02	0.75

X

Topic Importance

11.4			
	6.27		
		2.22	
			1.28

X

	D1	D2	D3	D4
To1	-0.42	-0.48	-0.57	-0.51
To2	-0.56	-0.52	0.45	0.46
To3	-0.65	0.62	0.28	-0.35
To4	-0.30	0.34	-0.63	0.63

Example from LAK15 tutorial "Topic modeling for learning analytics researchers" by V. Kovanovic et al.

Latent Semantic Indexing (LSI)

두 components 에 Doc 1, 2 의 유사성이 보존됩니다.

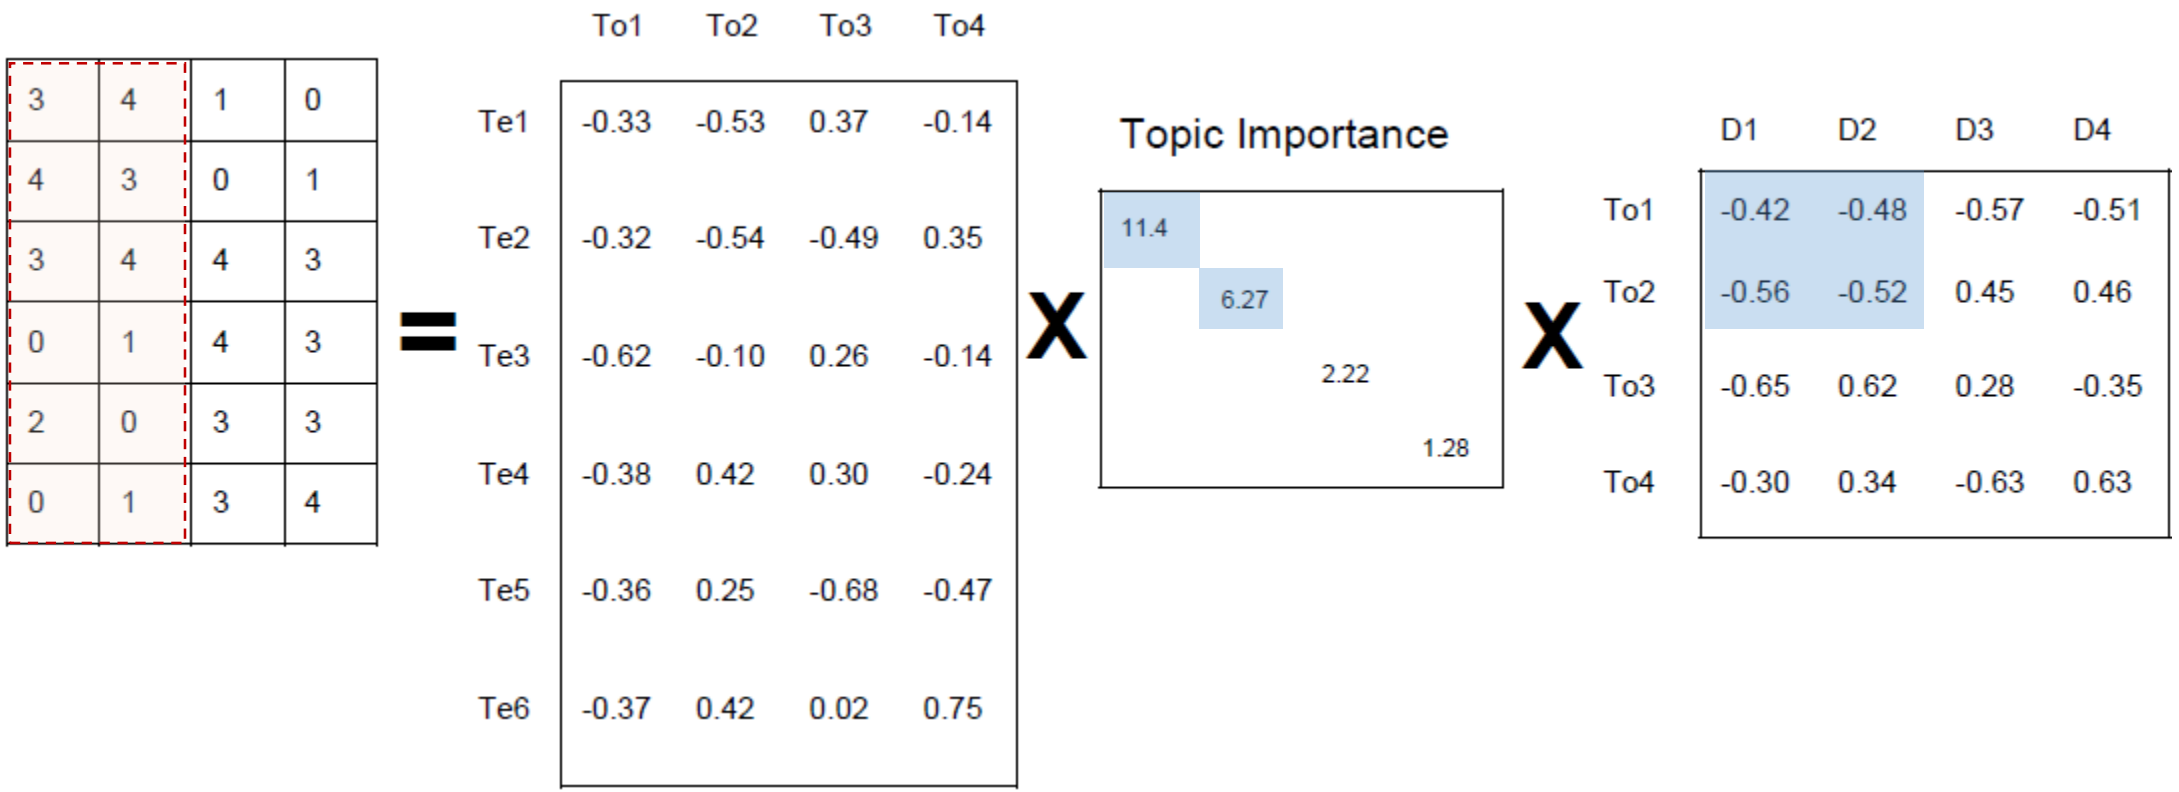

3	4	1	0
4	3	0	1
3	4	4	3
0	1	4	3
2	0	3	3
0	1	3	4

Example from LAK15 tutorial "Topic modeling for learning analytics researchers" by V. Kovanovic et al.

Latent Semantic Indexing (LSI)

- Co-occurrence 가 높은 단어들을 비슷한 topic vector 로 표현됩니다.
- 하지만 Word2Vec 처럼 음의 값이 있기 때문에 해석이 어렵습니다.

	To1	To2	To3	To4
Te1	-0.33	-0.53	0.37	-0.14
Te2	-0.32	-0.54	-0.49	0.35
Te3	-0.62	-0.10	0.26	-0.14
Te4	-0.38	0.42	0.30	-0.24
Te5	-0.36	0.25	-0.68	-0.47
Te6	-0.37	0.42	0.02	0.75

Probabilistic Latent Semantic Indexing

- pLSI 혹은 pLSA 라 불립니다.
- LSI 는 단어 – 문서 행렬로부터, 단어와 문서에 대한 k 차원의 topical representation을 학습합니다.
  - Word2Vec 처럼 각 벡터의 값으로부터 특정한 의미를 해석하기 어렵습니다.

Probabilistic Latent Semantic Indexing

- pLSI 는 확률 모형을 이용하여 단어와 문서를 표현합니다.
  - 각 문서는 topic probability vector 로 표현되며,
  - Topic vector 도 bag of words 와 비슷한 단어 벡터 형태로 표현됩니다.
  - 모델의 해석에 유용합니다.

Probabilistic Latent Semantic Indexing

- pLSI 는 문서 d 에서 단어 w 가 등장할 확률을 학습합니다.
- 문서 d 에서 단어 w 가 만들어지기 위해서 토픽 z 이라는 숨겨진 변수가 있다고 가정합니다.
  - $p(w,d) = p(d) \times \frac{p(w,d)}{p(d)} = p(d) \times p(w|d)$
  - $p(w,d) = \ p(d) \sum_z p(w|z) \times p(z|d)$

Probabilistic Latent Semantic Indexing

- $p(w,d) = p(d)\sum_z p(w|z) \times p(z|d)$
  - $p(z|d)$: 문서 d 에서 토픽 z 가 발생할 확률
  - $p(w|z)$: 토픽 z 에서 단어 w 가 발생할 확률
  - $p(z|d), p(w|z)$ 는 multinomial distribution 을 이용합니다.

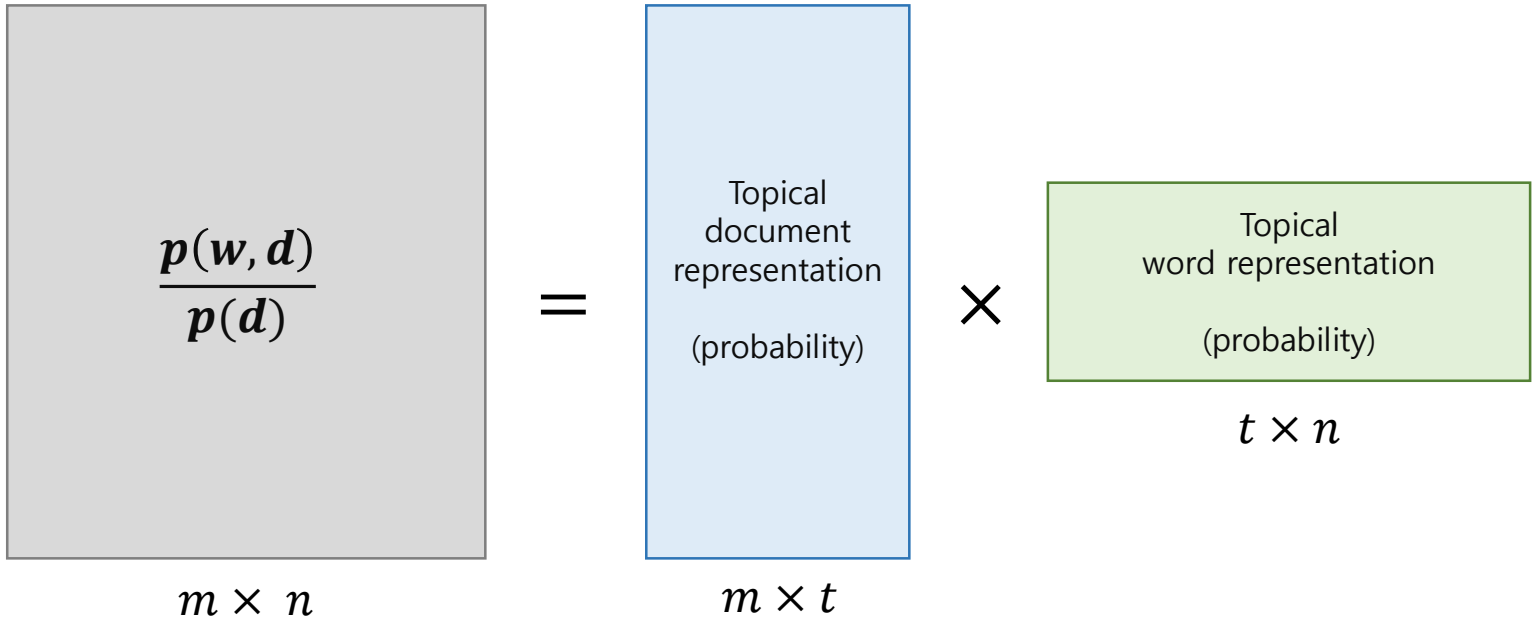

Probabilistic Latent Semantic Indexing

- pLSI 는 graphical model representation 으로 표현됩니다.
  - $p(w,d) = p(d)\sum_z p(w|z) \times p(z|d)$

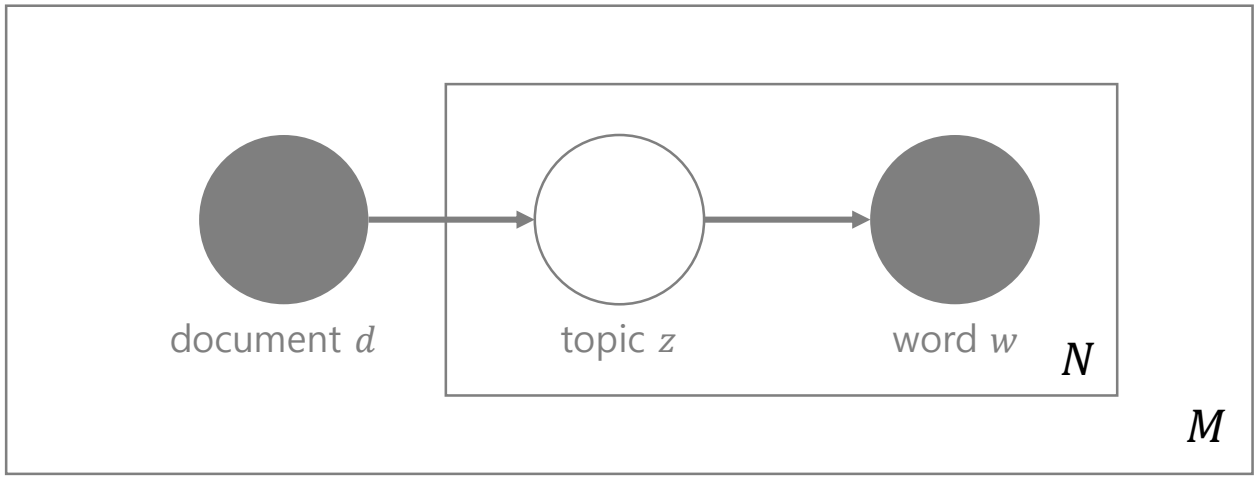

hidden variables

observed variables

N : number of words

M : number of docs

Probabilistic Latent Semantic Indexing

- $p(w,d) = p(d)\sum_z p(w|z) \times p(z|d)$
- z 는 학습데이터에 드러나지 않은 latent variables 입니다.
  - 학습이 어렵습니다.
  - Expected – Maximization 이라는 방법이 이용됩니다.

Probabilistic Latent Semantic Indexing

- pLSI 는 새로운 문서에 대한 $p(z|d)$ 를 학습하기 어렵습니다.
- pLSI 는 학습할 패러매터가 많아 over-fitting 이 일어날 가능성이 높습니다.

- Latent Dirichlet Allocation (LDA) 는 위 문제들을 해결하기 위하여 제안된 방법입니다.

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent dirichlet allocation. *Journal of machine Learning research*, *3*(Jan), 993-1022.

Latent Dirichlet Allocation

- LDA 는 topic modeling 을 위하여 가장 많이 이용되는 알고리즘입니다.
- Multinomial 을 이용하는 pLSI 와 달리 사용자 정의 parameter (α, β) 를 따르는 Dirichlet distribution 을 이용합니다.

  - pLSI : $p(w,d) = p(d)\sum_z p(w|z) \times p(z|d)$
  - LDA : $p(\boldsymbol{\theta}, \boldsymbol{\phi}, \boldsymbol{z}, \boldsymbol{w}\,|\alpha,\beta) = p(\theta|\alpha) \times p(\phi|\beta) \times \prod_{n=1}^{N} p(z_n|\theta)p(w_n|\phi, z_n)$

Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent dirichlet allocation. *Journal of machine Learning research*, *3*(Jan), 993-1022.

Latent Dirichlet Allocation

- LDA 의 학습 결과로 두 가지 정보를 얻을 수 있습니다.

  (1) 각 문서의 토픽 확률 분포

  (2) 각 토픽의 단어 확률 분포

$$p(\boldsymbol{\theta}, \boldsymbol{\phi}, \boldsymbol{z}, \boldsymbol{w} \,|\alpha, \beta) = p(\theta|\alpha) \times p(\phi|\beta) \times \prod_{n=1}^{N} p(z_n|\theta) p(w_n|\phi, z_n)$$

- 한 문서에서 등장한 단어들을 같은 토픽으로 묶는 효과가 있습니다.

Latent Dirichlet Allocation

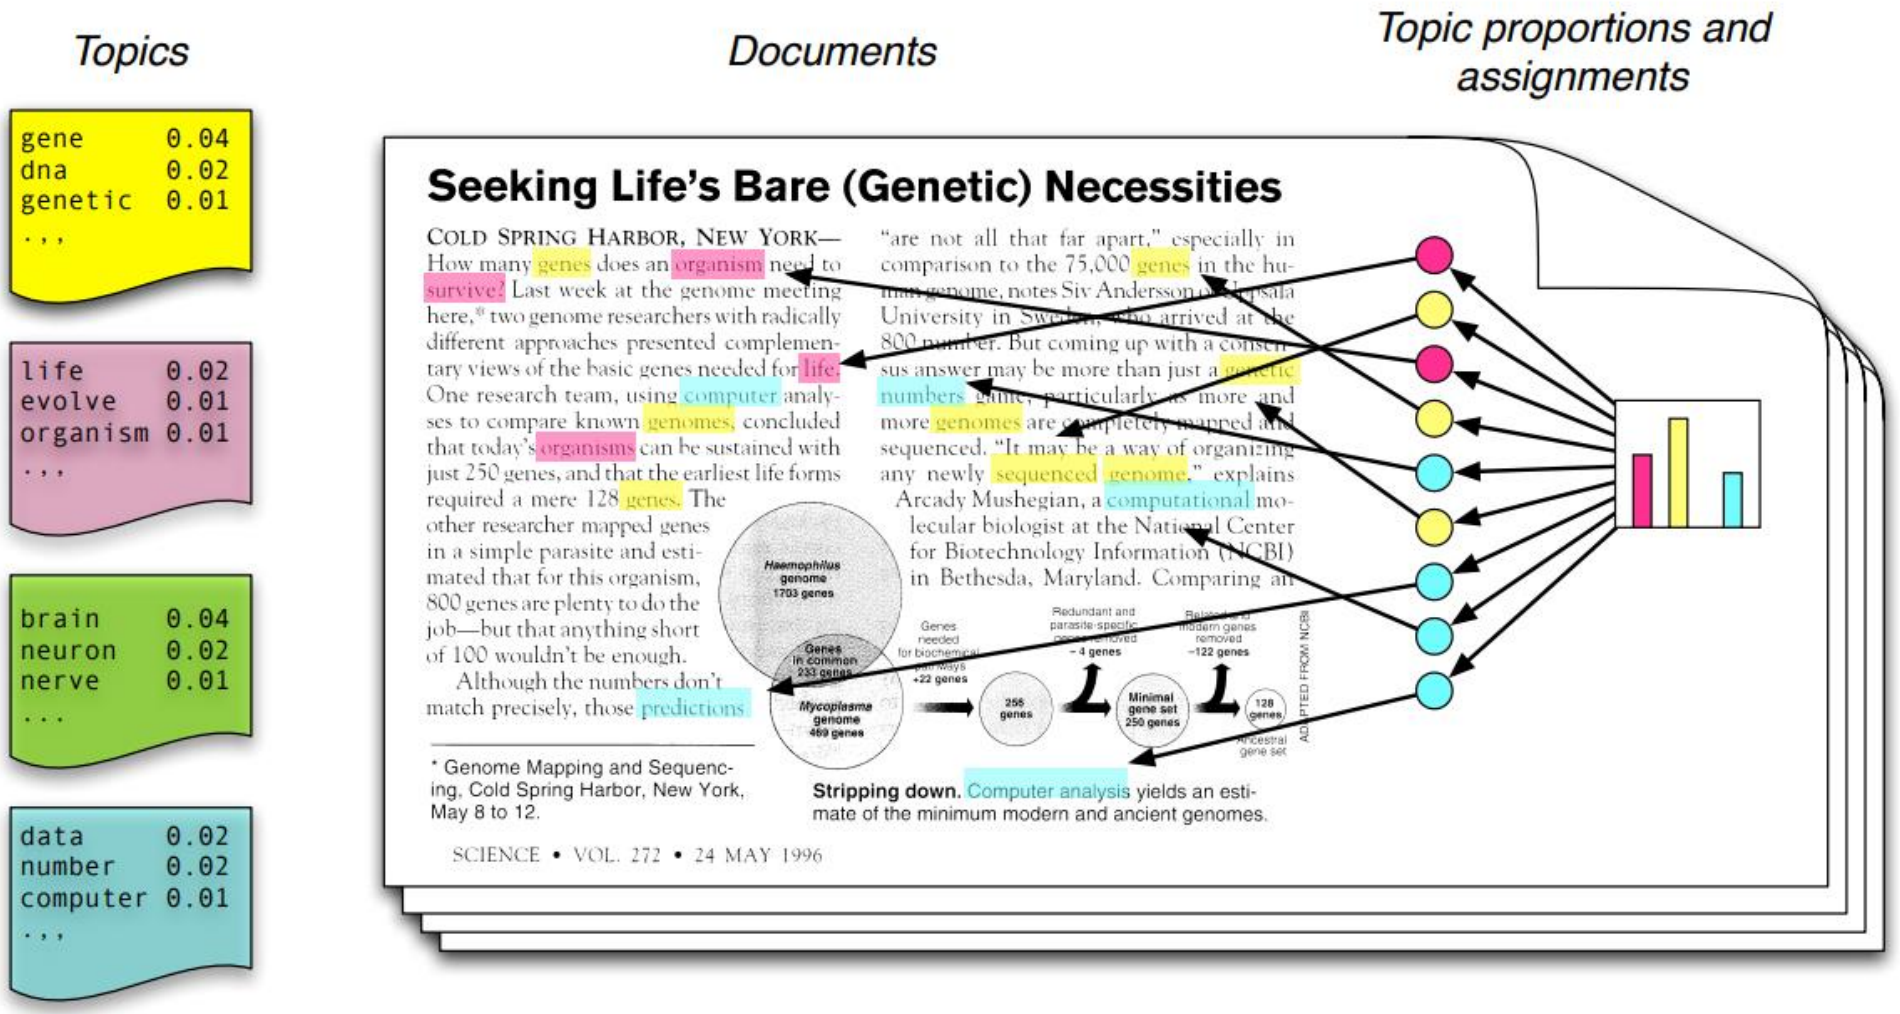

http://yosinski.com/mlss12/media/slides/MLSS-2012-Blei-Probabilistic-Topic-Models.pdf

Latent Dirichlet Allocation

- $p(\boldsymbol{\theta}, \boldsymbol{\phi}, \boldsymbol{z}, \boldsymbol{w} \,|\alpha, \beta) = p(\theta|\alpha) \times p(\phi|\beta) \times \prod_{n=1}^{N} p(z_n|\theta) p(w_n|\phi, z_n)$

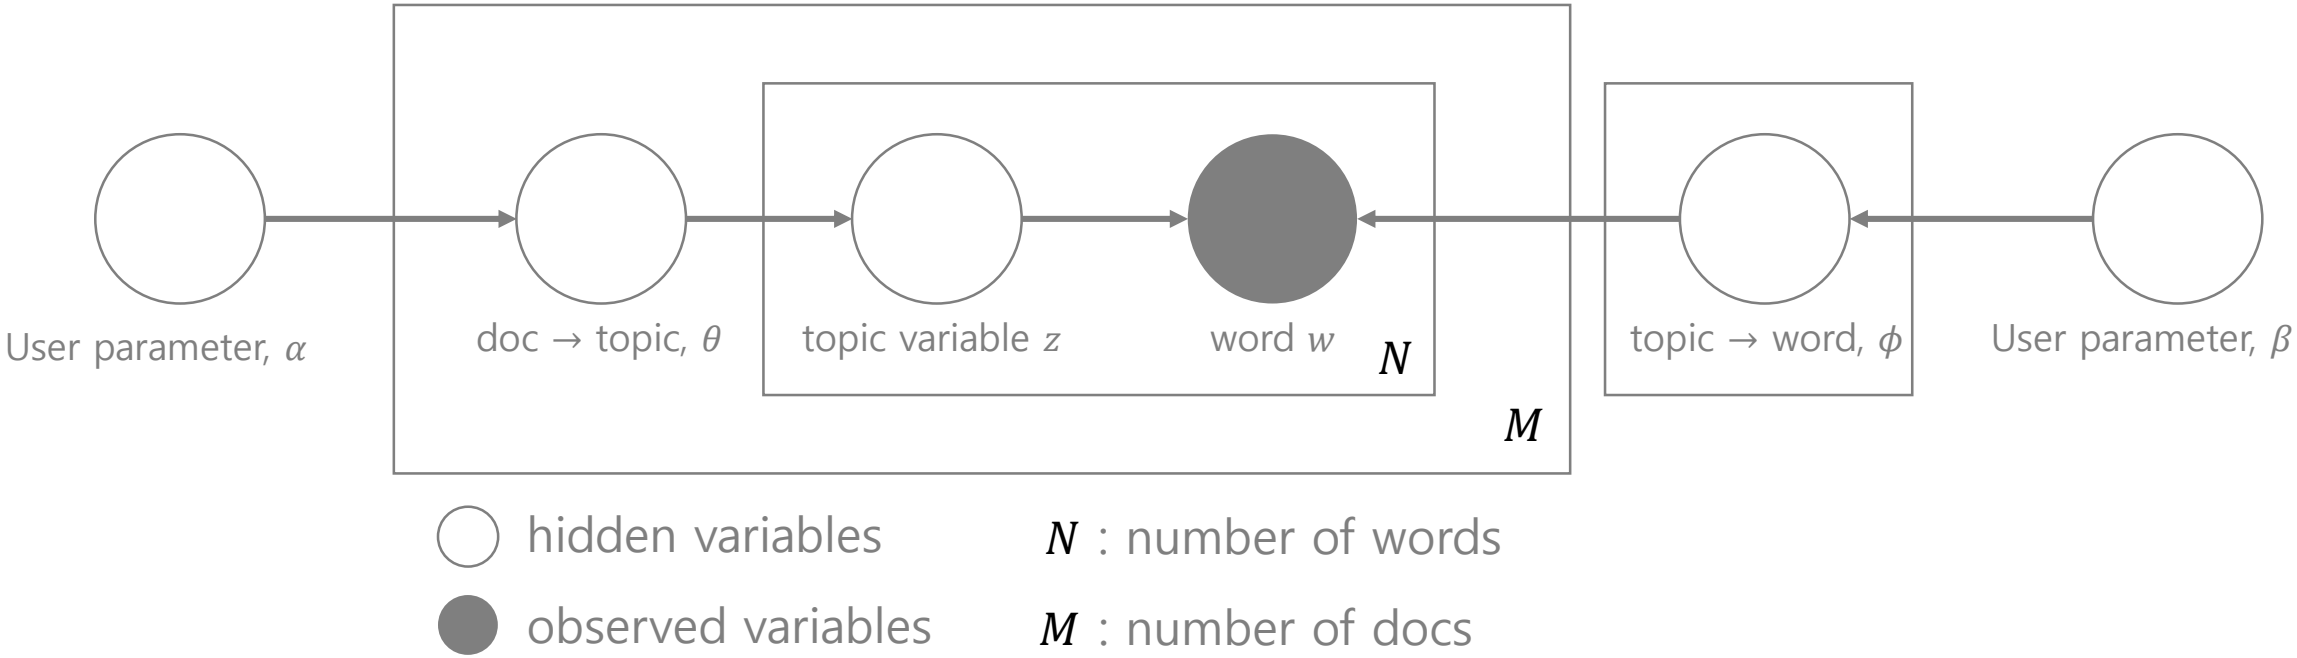

Latent Dirichlet Allocation

- LDA 의 학습에 대한 설명은 “밑바닥부터 시작하는 데이터 과학” 책을 참고하시면 좋습니다.
  - 해당 책의 LDA 구현 코드를 통하여 설명합니다.
  - 이 내용은 아래 블로그에도 잘 정리되어 있습니다.

https://ratsgo.github.io/from%20frequency%20to%20semantics/2017/07/09/lda/

Latent Dirichlet Allocation

- 그 외의 LDA 의 학습 과정에 관련한 직관적인 설명들은 아래의 블로그를 참고하세요.

- http://arongdari.tistory.com/entry/Latent-Dirichlet-Allocation
- http://www.4four.us/article/2010/11/latent-dirichlet-allocation-simply
- https://ratsgo.github.io/from%20frequency%20to%20semantics/2017/06/01/LDA/

Latent Dirichlet Allocation

- LDA 는 junk topic & term 이 존재합니다.
  - IMDB 영화리뷰를 이용한 LDA 학습 후, 각 토픽 별 발생확률이 가장 높은 단어들은 정보력이 적고 흔한 단어입니다.

Topic #1	Topic #2	Topic #3	Topic #4	Topic #5
the (0.0395)	the (0.0773)	the (0.0441)	the (0.0489)	the (0.0462)
and (0.0280)	and (0.0313)	to (0.0274)	of (0.0286)	of (0.0316)
to (0.0265)	to (0.0255)	of (0.0234)	to (0.0282)	to (0.0261)
of (0.0255)	of (0.0222)	is (0.0230)	and (0.0215)	is (0.0241)
is (0.0180)	in (0.0212)	and (0.0226)	it (0.0182)	and (0.0181)
in (0.0156)	is (0.0162)	in (0.0152)	is (0.0172)	in (0.0173)
this (0.0153)	that (0.0154)	that (0.0146)	in (0.0145)	it (0.0162)
it (0.0121)	it (0.0151)	this (0.0141)	movie (0.0139)	this (0.0137)
with (0.0110)	this (0.0141)	it (0.0139)	that (0.0126)	that (0.0127)
that (0.0107)	movie (0.0101)	movie (0.0099)	this (0.0116)	movie (0.0117)

- Newman, D., Noh, Y., Talley, E., Karimi, S., & Baldwin, T. (2010, June). Evaluating topic models for digital libraries. In *Proceedings of the 10th annual joint conference on Digital libraries* (pp. 215-224). ACM.

Latent Dirichlet Allocation

- LDA 는 junk topic & term 이 존재합니다.
  - Junk topic 이란 많은 문서들에서 거의 이용되지 않는 topic 이나 혹은 모든 문서에서 이용되는 topic 입니다.
  - 이를 방지하기 위해서는 전처리 과정에서 불필요한 단어들을 미리 제거하는 것이 좋습니다.
    - Term / document frequency filtering
    - Stopwords removal

• Newman, D., Noh, Y., Talley, E., Karimi, S., & Baldwin, T. (2010, June). Evaluating topic models for digital libraries. In *Proceedings of the 10th annual joint conference on Digital libraries* (pp. 215-224). ACM.

LDA vs Word2Vec

- LDA 와 Word2Vec 은 모두 단어를 벡터 공간의 좌표로 표현합니다.
  - Word2Vec 의 공간은 각 차원을 해석하기 어렵습니다만, LDA 는 확률을 표현하는 벡터이기 때문에 해석이 가능합니다.
- Word2Vec 은 좌/우 단어의 분포를 contexts 로 이용합니다만, LDA 는 한 문서에서 함께 등장한 co-occurrences 를 contexts 로 이용합니다.
  - Topically similar vs. contextually similar

Latent Dirichlet Allocation

- Topic 의 개수는 일단 크게 잡는 쪽이 좋습니다.
  - Perplexity 와 같은 evaluation metric 이 있습니다만, 현실적인 솔루션은 일단 여러 개의 topics 을 추출하고, 비슷한 topics 은 후처리로 묶는 것이 좋습니다.
  - topic 개수가 작으면 여러 개의 topic 이 하나로 뭉치는 경향도 있습니다.
  - LDA 는 co-occurrence 를 이용하는 단어의 군집화와 비슷합니다.

pyLDAvis

- LDA 의 학습 결과를 시각적으로 표현합니다.
  - interactive plot 은 topic space 를 이해하는데 매우 유용합니다.
  - Topic keywords 를 추출할 수도 있습니다.

pyLDAvis

```
In [15]: pyLDAvis.display(loaded_pyldavis)
```

Out [15]:

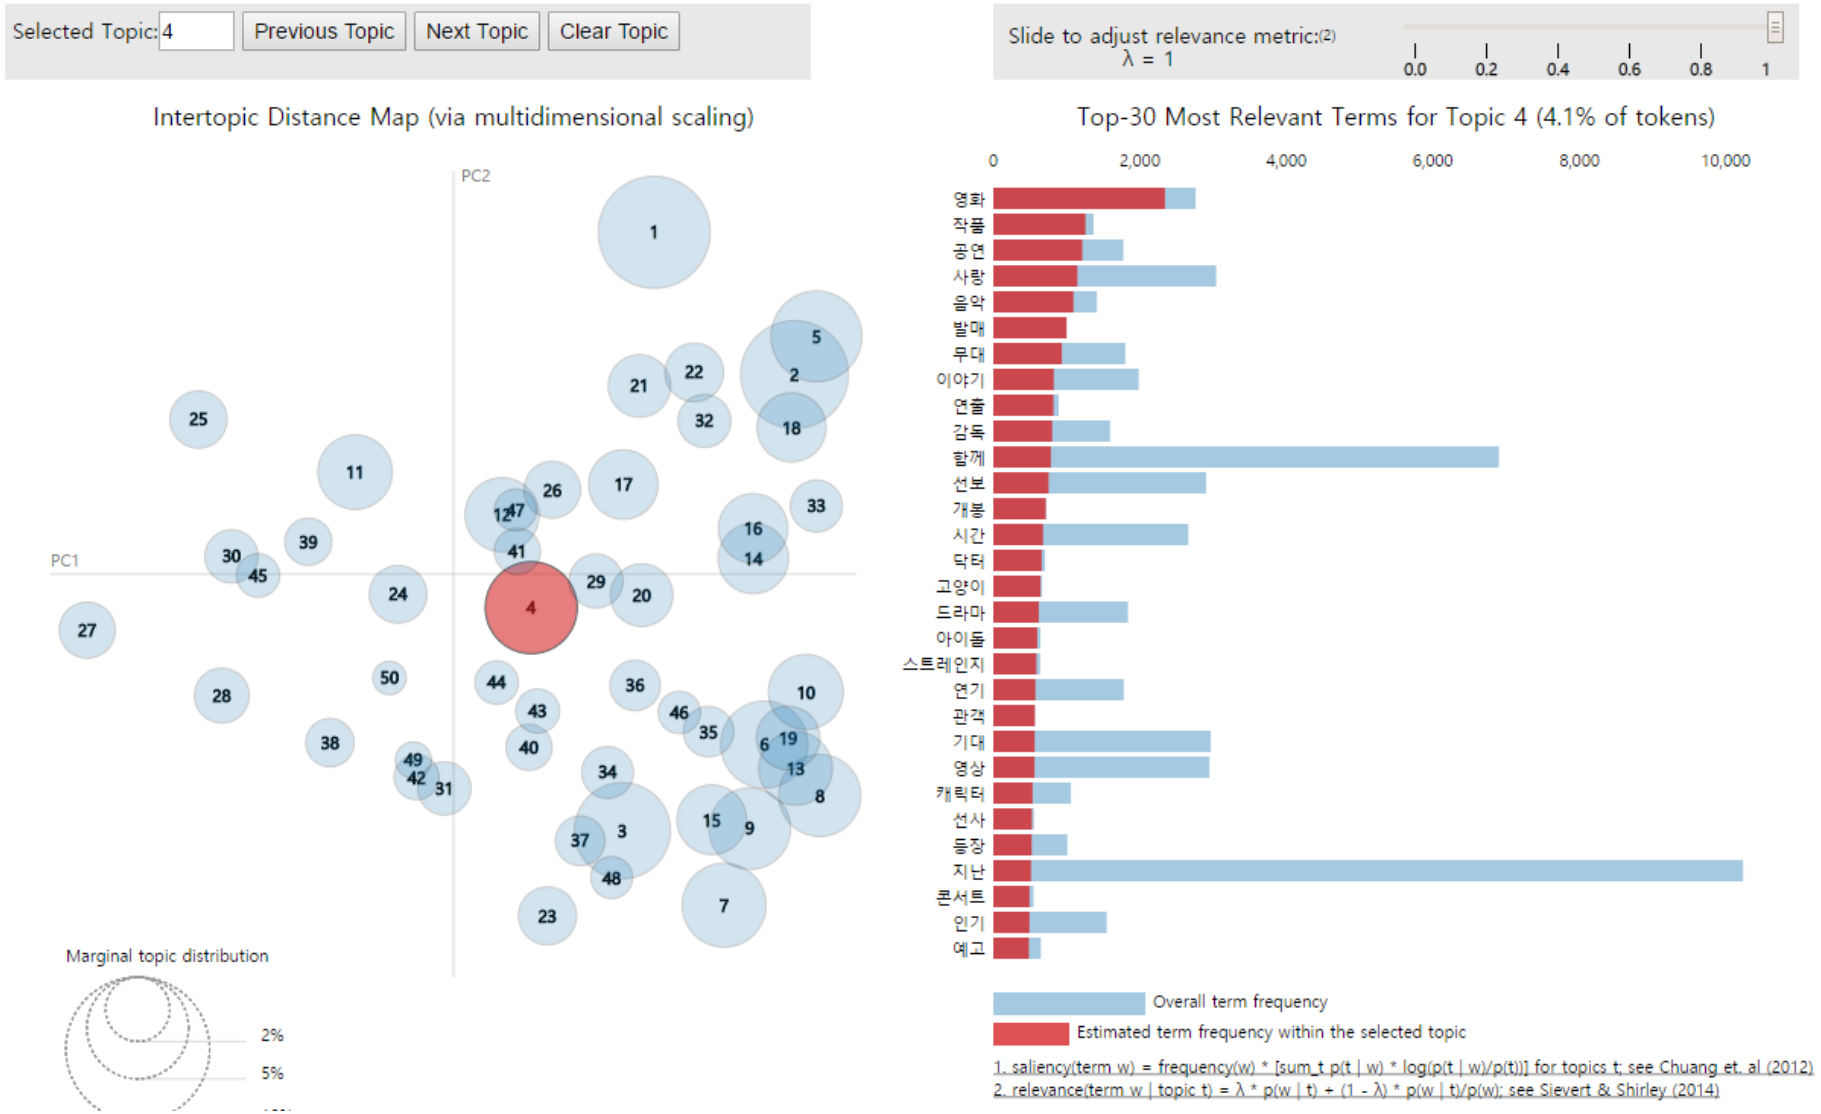

pyLDAvis

- pyLDAvis 의 왼쪽에는 각 토픽들을 2 차원의 scatter plot 으로 표현합니다.
  - Topic 의 단어 생성 확률 분포 행렬에 Principal Component Analysis 를 적용하여 2 차원의 embedding vector 를 학습합니다.

pyLDAvis

- pyLDAvis 의 오른쪽에는 각 토픽의 키워드 (topic labels) 이 선택됩니다.
  - Keywords 점수는 coverage 와 discriminative power 와의 선형 결합입니다.
  - $relevance(word_i, topic_j) = \lambda \cdot P(word_i|topic_j) + (1 - \lambda) \cdot \frac{P(word_i|\, topic_j)}{P(word_i)}$

History

Latent Semantic Indexing (LSI), 1990	• Grouping semantically similar terms to a topic • Using matrix decomposition
Probabilistic LSI (pLSI), 1999	• Using probabilistic model
Latent Dirichlet Allocation (LDA), 2003	• Using (more general) probabilistic model
now	• Using distributed representation

https://www.nextobe.com/single-post/2017/09/05/Anything2Vec-Word2Vec%EC%9D%98-NLP-%EC%A0%95%EB%B3%B5%EA%B8%B0